

Documentação Técnica de Referência Inteligência Computacional

Projeto: Detecção de Fraude em Ambientes Desbalanceados

Autor Responsável: Artur Machado

Grupo de Trabalho: Artur, Ruan, Lúcio

Contexto: Planejamento e Arquitetura de IC, compondo a entrega da Semana 1

PARTE 1: ESTRUTURA E CONTEÚDO PARA 'TECNICAS_IC.md'

Este bloco reúne os insumos necessários para justificar a modelagem inicial e mitigar os efeitos de bases altamente desbalanceadas, fundamentando as decisões teóricas do projeto.

1.1 O Problema Central: Desbalanceamento Extremo de Classes

O cenário de detecção de fraudes financeiras é caracterizado por um severo desequilíbrio estatístico. Na base sugerida Credit Card Fraud Detection (Kaggle), existem apenas 492 instâncias fraudulentas inseridas em um universo de 284.807 transações (aproximadamente 0,17% do total). Na base Default of Credit Card Clients (UCI), a inadimplência também se manifesta de forma minoritária em relação aos clientes adimplentes.

Modelos preditivos tradicionais expostos a esse nível de desbalanceamento tendem a convergir para a classificação da classe majoritária (falso negativo massivo), apresentando uma falsa alta acurácia global enquanto falham completamente em identificar o risco real.

1.2 Abordagens de Mitigação do Desbalanceamento

Para permitir que as técnicas de Inteligência Computacional aprendam os padrões das fraudes, devem ser avaliadas e documentadas as seguintes estratégias de amostragem e penalização:

SMOTE (Synthetic Minority Over-sampling Technique): Algoritmo de sobreamostragem que cria instâncias sintéticas da classe minoritária (fraude) através da interpolação de vizinhos mais próximos (KNN), em vez de simplesmente duplicar registros. Evita o overfitting mas pode introduzir ruído nas fronteiras de decisão.

Class Weight (Pesos de Classes Penalizados): Modificação direta na função de custo do algoritmo de aprendizado. Atribui um peso inversamente proporcional à frequência da classe, punindo severamente o erro do modelo ao errar uma transação fraudulenta.

Amostragem Estratificada (Stratified K-Fold): Garantia metodológica aplicada na divisão dos dados de treino e teste. Assegura que a proporção original de 0,17% de fraudes seja mantida em todas as dobras de validação cruzada, prevenindo partições sem nenhum exemplo de fraude.

1.3 Análise Comparativa de Técnicas Científicas de IC

Técnica de IC	Vantagens no Contexto de Fraude	Desvantagens / Desafios
Random Forest (Floresta Aleatória)	Altamente robusto contra overfitting; manipula bem distribuições desbalanceadas através do isolamento de subamostras e construção de árvores independentes; provê métricas nativas de importância de atributos.	Pode se tornar computacionalmente lento para inferência em tempo real à medida que o número de estimadores cresce; consome muita memória com bases massivas.
Redes Neurais Artificiais	Extrema capacidade de capturar relações matemáticas altamente não-lineares e padrões complexos de comportamento financeiro camuflado.	Exige grande volume de dados para parametrização; risco severo de sobreajuste na classe majoritária se não houver forte penalização; natureza de 'caixa-preta' (baixa explicabilidade).
SVM (Support Vector Machines)	Excelente capacidade de generalização espacial através de funções de Kernel; foca na maximização das margens de decisão, sendo historicamente eficiente para a delimitação de anomalias.	Custo computacional de treinamento proibitivo para bases muito extensas (complexidade quadrática em relação ao número de transações); sensível a ruídos introduzidos por sobreamostragem.

1.4 Justificativa Preliminar da Escolha

Com base no levantamento, a recomendação inicial pende para o uso de Random Forest devido à estabilidade nativa com dados desbalanceados e à capacidade de extrair a importância das features. Alternativamente, arquiteturas de Redes Neurais do tipo Autoencoder (aprendizado não supervisionado focado no erro de reconstrução da classe legítima) despontam como uma abordagem inovadora e cientificamente rica para complementar o agrupamento.

1.5 Métricas Críticas de Avaliação

PROIBIÇÃO METODOLÓGICA: Sob hipótese alguma a Acurácia Global deverá ser utilizada como métrica de sucesso neste projeto. Um modelo estúpido que classifique 100% das transações como legítimas obteria 99,83% de acurácia na base do Kaggle, operando um desastre financeiro real ao ignorar todas as fraudes.

As métricas mandatórias a serem adotadas na validação do pipeline são:

AUC-ROC: Avalia a capacidade global do modelo em discriminar entre transações legítimas e fraudulentas independentemente do limiar de probabilidade adotado.

F1-Score: Média harmônica entre Precisão e Recall. Garante um equilíbrio forçado, penalizando modelos que otimizam apenas uma das pontas.

Precisão (Precision): Percentual de alertas gerados que eram fraudes reais. Crucial para mensurar o custo operacional decorrente de falsos positivos.

Recall (Sensibilidade): Percentual de fraudes reais que foram interceptadas pelo sistema. É a métrica mais crítica para mitigar o prejuízo financeiro direto.

Matriz de Confusão & Curva Precision-Recall: Ferramentas visuais indispensáveis para mapear a distribuição exata dos erros (falsos alarmes vs. fraudes perdidas), com foco especial na curva PR dada a raridade da classe positiva.

PARTE 2: ESTRUTURA E CONTEÚDO PARA 'PLANO_IC.md'

Este bloco detalha o planejamento prático da engenharia de dados, o roteiro de integração entre a modelagem não supervisionada (clustering) e supervisionada (IC), além do cronograma operacional das Semanas 4 e 5.

2.1 Estratégias de Integração: Agrupamento + Inteligência Computacional

O grupo deverá se reunir para deliberar e formalizar a escolha de uma das três seguintes opções de integração arquitetural:

Opção 1: Rótulo do Cluster como Atributo (Feature Engineering): O pipeline de clustering (K-Means/DBSCAN) processa os dados primeiro. O ID do cluster gerado para cada transação é injetado como uma nova coluna categórica no dataset. O modelo de IC utiliza essa feature enriquecida para realizar a classificação final.

Opção 2: Clusters para Definição de Recomendações e Submodelos: Os dados são segmentados fisicamente através dos perfis comportamentais mapeados pelos clusters (ex: perfis de alta frequência, perfis corporativos, perfis sazonais). Um modelo específico de IC é treinado exclusivamente para atender e monitorar cada um dos clusters individualmente.

Opção 3: Validação por Contraste (Baseline vs. Híbrido): Abordagem focada em experimentação acadêmica rigorosa. Desenvolve-se um modelo puramente supervisionado (Sem Clusters) e compara-se estatisticamente o seu desempenho contra o modelo híbrido (Com Clusters) via métricas F1 e AUC-ROC para provar o ganho real do agrupamento.

2.2 Pipeline de Processamento e Distribuição de Papéis (Semanas 4-5)

O fluxo de execução dos dados e o sequenciamento de atividades entre os integrantes do grupo está consolidado conforme a estrutura linear abaixo:

Dados Brutos



Pré-processamento [Responsável: Ruan]



Clustering (K-Means/DBSCAN) [Responsável: Ruan]



Fusão de Features Originais + Rótulos de Clusters



Modelo de Inteligência Computacional [Responsável: Artur]



Predição Final + Atribuição de Score de Confiança

2.3 Infraestrutura Tecnológica e Bibliotecas

Serão utilizadas as seguintes ferramentas no ecossistema Python para a sustentação do pipeline do projeto:

Scikit-Learn: Sustentação do K-Means, DBSCAN, Random Forest, Árvores de Decisão e funções utilitárias de métricas.

Imbalanced-Learn (imblearn): Implementação nativa do SMOTE e utilitários de amostragem estratificada.

Pandas & NumPy: Manipulação matricial de alta performance e engenharia de tabelas.

2.4 Cronograma Detalhado de Implementação (Semanas 4 e 5)

Período	Atividades de Desenvolvimento	Entregáveis Esperados
Semana 4	Integração das bases pré-processadas por Ruan; Engenharia de Atributos com a inclusão dos dados extraídos dos clusters; Ajuste inicial do modelo de Inteligência Computacional (Artur) sob validação estratificada.	Script de fusão de dados concluído; Primeira versão do classificador rodando sobre os clusters.
Semana 5	Otimização refinada de hiperparâmetros (via algoritmos de busca/AG); Extração e plotagem das matrizes de confusão e curvas Precision-Recall; Documentação final comparativa com e sem uso de agrupamento.	Pipeline integrado fim a fim; Gráficos de performance consolidados; Relatório de explicabilidade do modelo pronto.

PARTE 3: PREMISSAS CRÍTICAS E TRATAMENTO DE DADOS

COMPREENSÃO DAS VARIÁVEIS V1-V28: As variáveis nomeadas de V1 a V28 no dataset do Kaggle já passaram por uma transformação matemática via PCA (Principal Component Analysis) por questões de privacidade bancária. Elas não possuem significado de negócio direto interpretável, o que impede análises intuitivas sobre elas. O modelo deve tratá-las puramente de forma estatística.

As únicas duas variáveis originais e totalmente interpretáveis na base do Kaggle são:

Time (Tempo): Segundos decorridos entre a transação atual e a primeira transação registrada no dataset. Permite capturar janelas temporais de ataques coordenados.

Amount (Valor): O valor financeiro absoluto envolvido na transação. É de extrema relevância para associar o comportamento de risco ao volume monetário movimentado.

PROIBIÇÃO DE REMOÇÃO DE OUTLIERS: O grupo não deve aplicar remoção cega de outliers estatísticos durante a fase de limpeza inicial conduzida por Ruan. Em problemas de fraude bancária, os comportamentos bizarros e anômalos que fogem drasticamente do padrão estatístico padrão são, em grande parte das vezes, as próprias fraudes que estamos tentando capturar. Eliminar outliers equivaleria a apagar o histórico de fraudes da base de dados.

Para fechar a Semana 1, submeto os seguintes tópicos para decisão conjunta com o grupo:

Definição da Abordagem de Integração: Qual das opções (1, 2 ou 3) utilizaremos como arquitetura padrão?

Validação da Técnica de IC: Confirmaremos a Random Forest pela explicabilidade facilitada ou faremos uso de uma Rede Neural de detecção de novidades?

Infraestrutura: Todos os integrantes devem possuir as bibliotecas scikit-learn e imblearn operacionais em seus ambientes de desenvolvimento.