

TRABALHO FINAL INTEGRADOR

Agrupamento de Dados e Inteligência Computacional para Predição, Recomendação e Apoio à Decisão

Item	Descrição
Duração	5 semanas
Formato	Grupos de 3 alunos
Linguagem obrigatória	Python
Entrega final	Código, relatório técnico, apresentação e demonstração prática
Valor sugerido	100 pontos

1. Contextualização

Este trabalho final integrador tem como objetivo desenvolver uma solução computacional aplicada, utilizando técnicas de **Agrupamento de Dados** combinadas com métodos de **Inteligência Computacional** para resolver um problema de predição, recomendação, priorização, detecção de risco, explicação de perfis ou apoio à decisão.

A proposta considera que o agrupamento não deve ser usado apenas para separar objetos em grupos, mas como uma etapa estratégica para descobrir perfis, padrões, segmentos ou anomalias. A Inteligência Computacional, por sua vez, deve ampliar essa análise por meio de modelos capazes de prever, recomendar, otimizar ou apoiar decisões. Assim, as duas disciplinas devem aparecer de forma equilibrada e integrada no produto final.

O cenário de cada grupo será previamente definido pelos professores. Portanto, a primeira entrega já deverá conter tratamento inicial da base de dados e não apenas a escolha do tema.

2. Objetivo geral

Desenvolver, em Python, uma solução prática que utilize Agrupamento de Dados como etapa de descoberta de perfis, padrões ou anomalias e integre pelo menos uma técnica de Inteligência Computacional para realizar uma tarefa aplicada de predição, recomendação, classificação, otimização, priorização ou apoio à decisão.

3. Fluxo geral esperado da solução

Base pública -> Análise exploratória -> Pré-processamento -> Agrupamento -> Interpretação dos clusters -> Inteligência Computacional -> Predição/Recomendação/Decisão

Observação: não serão aceitos trabalhos compostos por duas partes desconectadas. A etapa de Agrupamento de Dados deverá contribuir objetivamente para a etapa de Inteligência Computacional.

4. Requisitos obrigatórios

4.1. Requisitos gerais do projeto

- Utilizar o cenário previamente definido pelos professores.
- Utilizar uma base de dados pública compatível com o cenário.
- Desenvolver a solução em Python.
- Organizar o código em notebook ou scripts executáveis.
- Apresentar análise exploratória inicial da base.
- Realizar tratamento mínimo dos dados, incluindo ausentes, duplicidades, inconsistências e outliers quando aplicável.
- Documentar as decisões tomadas durante o desenvolvimento.
- Entregar relatório técnico, código e apresentação final.
- Demonstrar a execução prática da solução.
- Indicar limitações, riscos, pressupostos adotados e possíveis melhorias.

4.2. Requisitos específicos de Agrupamento de Dados

- Definir quais atributos serão utilizados para o agrupamento.
- Justificar a escolha dos atributos usados na clusterização.
- Aplicar normalização, padronização, transformação ou redução de dimensionalidade quando necessário.
- Justificar a medida de distância ou similaridade utilizada.
- Aplicar pelo menos dois algoritmos de agrupamento.
- Comparar os resultados dos algoritmos aplicados.
- Avaliar os clusters com pelo menos duas métricas adequadas.
- Interpretar os grupos encontrados no contexto do problema.
- Nomear ou caracterizar os perfis identificados.
- Explicar como os clusters serão utilizados na etapa de Inteligência Computacional.

Exemplos de algoritmos aceitos: K-Means, K-Medoids, DBSCAN, Agglomerative Clustering, Bisecting K-Means, Mean Shift, Gaussian Mixture Models, SOM, clustering com embeddings, clustering após PCA, SVD ou autoencoder, Birch, e demais vistos na disciplina.

Exemplos de métricas aceitas: silhouette score, Davies-Bouldin, Calinski-Harabasz, SSE/elbow, análise de estabilidade, pureza dos clusters quando houver rótulos reais apenas para avaliação, e matriz de comparação entre clusters e classes reais quando aplicável.

4.3. Requisitos específicos de Inteligência Computacional

- Aplicar pelo menos uma técnica de Inteligência Computacional relacionada ao cenário.
- Justificar por que a técnica foi escolhida.
- Definir claramente a tarefa de Inteligência Computacional: predição, recomendação, classificação, regressão, otimização, priorização ou apoio à decisão.
- Construir um modelo, mecanismo ou pipeline funcional.
- Treinar, testar ou validar a técnica utilizada, quando aplicável.
- Utilizar métricas adequadas para avaliar o desempenho.
- Comparar o desempenho da solução com e sem o uso dos clusters, sempre que possível.
- Explicar como a técnica de Inteligência Computacional contribui para a decisão final.
- Apresentar uma saída prática do sistema.
- Discutir limitações do modelo inteligente.

Técnicas aceitas: árvore de decisão, Random Forest, rede neural artificial, rede convolucional para cenários com imagens, autoencoder, algoritmo genético, sistema de recomendação baseado em similaridade, sistema de recomendação baseado em perfil, modelo de classificação, modelo de regressão, modelo de ranking, modelo híbrido de clusterização + predição, e modelo híbrido de clusterização + recomendação.

Exemplos de métricas para Inteligência Computacional: para classificação: acurácia, precisão, revocação, F1-score, matriz de confusão e AUC-ROC; para regressão: MAE, MSE, RMSE e R^2 ; para recomendação: precisão@k, recall@k, cobertura, diversidade e análise qualitativa; para otimização: valor da função objetivo, evolução por geração e comparação com solução sem otimização.

4.4. Requisitos de integração entre as disciplinas

A integração entre Agrupamento de Dados e Inteligência Computacional é obrigatória. Cada grupo deverá cumprir pelo menos duas das estratégias abaixo:

- Usar o rótulo do cluster como atributo de entrada em um modelo preditivo.
- Usar os clusters para definir recomendações personalizadas.
- Usar agrupamento para identificar perfis e depois treinar um classificador explicativo.
- Usar algoritmo genético para otimizar parâmetros do agrupamento.
- Usar algoritmo genético para selecionar atributos antes do agrupamento e da predição.
- Usar autoencoder ou rede neural para gerar representações e depois aplicar clustering.
- Comparar um modelo de Inteligência Computacional com e sem informação dos clusters.
- Usar os clusters como base para apoio à decisão.
- Usar DBSCAN ou outro método para detectar anomalias e depois classificar o risco.
- Usar árvore de decisão para explicar os perfis formados pelos clusters.

Importante: não será suficiente executar um algoritmo de agrupamento e, separadamente, um modelo de Inteligência Computacional. O grupo deverá demonstrar como uma etapa contribui para a outra.

5. Papéis dos alunos no grupo

Cada grupo deverá ter 3 alunos. A divisão de papéis tem a finalidade de organizar as responsabilidades, mas todos os integrantes deverão compreender o projeto completo e conseguir explicar a solução final.

Aluno 1 - Responsável por Dados, Pipeline e Integração

- Carregar a base de dados e documentar sua origem.
- Realizar análise exploratória.
- Tratar valores ausentes, duplicidades e inconsistências.
- Transformar variáveis categóricas e preparar atributos numéricos.
- Organizar o pipeline de dados.
- Preparar os conjuntos usados por agrupamento e Inteligência Computacional.
- Manter o repositório ou os arquivos do projeto organizados.
- Apoiar a integração entre as etapas.

Participação esperada: Este aluno deve garantir que os dados estejam adequados tanto para a etapa de Agrupamento de Dados quanto para a etapa de Inteligência Computacional.

Aluno 2 - Responsável por Agrupamento de Dados

- Escolher atributos para clusterização.
- Justificar medidas de distância ou similaridade.
- Aplicar pelo menos dois algoritmos de agrupamento.
- Avaliar e comparar clusters.
- Interpretar os perfis encontrados.
- Gerar a saída do agrupamento que será usada na Inteligência Computacional.
- Explicar limitações dos métodos de agrupamento utilizados.

Participação esperada: Este aluno deve demonstrar domínio dos conceitos de Agrupamento de Dados e explicar por que os grupos encontrados fazem sentido no problema.

Aluno 3 - Responsável por Inteligência Computacional e Decisão

- Escolher a técnica de Inteligência Computacional.
- Definir a tarefa final: predição, recomendação, classificação, otimização ou decisão.
- Construir e avaliar o modelo inteligente.
- Comparar solução com e sem clusters, quando aplicável.
- Explicar a saída final da solução.
- Demonstrar a utilidade prática do produto final.
- Apoiar a apresentação e a defesa da solução.

Participação esperada: Este aluno deve demonstrar que a Inteligência Computacional contribuiu diretamente para a decisão final e não foi apenas adicionada ao trabalho.

6. Cenários sugeridos e bases públicas

Os cenários abaixo devem ser mantidos conforme a distribuição feita pelos professores. Cada grupo deverá desenvolver uma solução aplicada dentro do cenário atribuído.

Cenário 1 - Segmentação de clientes e recomendação de produtos – Não tem Grupo

Problema: Uma empresa de comércio eletrônico deseja compreender melhor seus clientes e recomendar produtos, categorias ou campanhas com base no perfil de compra.

Pergunta central: Como agrupar clientes por comportamento de compra e usar esses grupos para recomendar produtos ou campanhas?

Base(s) de dados sugerida(s):

- **Online Retail - UCI Machine Learning Repository:** Base transacional de uma loja online do Reino Unido, com transações entre 01/12/2010 e 09/12/2011, adequada para classificação e agrupamento. Link: <https://archive.ics.uci.edu/dataset/352/online%20Retail>

Pipeline possível: Transações de compra -> indicadores por cliente -> agrupamento de clientes -> identificação dos perfis -> recomendação de produtos ou campanhas por cluster.

Técnicas possíveis: K-Means, DBSCAN, K-Medoids, algoritmo genético para seleção de atributos ou otimização de K, árvore de decisão para explicar perfis e recomendação baseada nos produtos mais comprados por cluster.

Exemplo de saída esperada: O sistema poderá classificar um cliente em um perfil, como recorrente de alto valor, e recomendar produtos frequentemente comprados por clientes semelhantes.

Cenário 2 - Predição de churn e recomendação de ações de retenção - (João, André, Fernando) OK

Problema: Empresas de assinatura, telefonia, internet e serviços digitais precisam identificar clientes com maior risco de cancelamento.

Pergunta central: Como agrupar clientes por perfil de uso e usar esses grupos para prever churn e recomendar ações de retenção?

Base(s) de dados sugerida(s):

- **Telco Customer Churn - Kaggle:** Base com 7.043 clientes, 21 colunas e variável-alvo Churn. Link: <https://www.kaggle.com/datasets/blaschar/telco-customer-churn>
- **Telco Customer Churn - IBM Sample Data:** Base fictícia de empresa de telecomunicações, com informações de serviços contratados, cobranças e churn. Link: <https://www.ibm.com/docs/en/cognos-analytics/12.0.x?topic=samples-telco-customer-churn>

Pipeline possível: Dados de clientes -> agrupamento por perfil de contrato e uso -> predição de churn -> recomendação de ação de retenção.

Técnicas possíveis: K-Means, agrupamento hierárquico, Random Forest, árvore de decisão, rede neural e algoritmo genético para seleção de atributos.

Exemplo de saída esperada: O sistema poderá identificar clientes em risco e sugerir ações como contato prioritário, desconto, mudança de plano ou campanha personalizada.

Cenário 3 - Priorização inteligente de leads em campanhas de marketing – Não tem grupo

Problema: Uma empresa ou instituição financeira realiza campanhas com muitos contatos, mas precisa priorizar clientes com maior chance de conversão.

Pergunta central: Como agrupar clientes por perfil e prever quais têm maior chance de aceitar uma oferta?

Base(s) de dados sugerida(s):

- **Bank Marketing - UCI Machine Learning Repository:** Base relacionada a campanhas de marketing direto de uma instituição bancária portuguesa por telefone, com objetivo de prever assinatura de depósito a prazo. Link: <https://archive.ics.uci.edu/dataset/222/bank%2Bmarketing>

Pipeline possível: Dados de campanha -> agrupamento de clientes/leads -> predição de conversão -> priorização comercial.

Técnicas possíveis: K-Means, DBSCAN, árvore de decisão, rede neural, algoritmo genético para seleção de variáveis e modelo de ranking.

Exemplo de saída esperada: O sistema poderá classificar leads como alta, média ou baixa prioridade, explicando quais características justificam a recomendação.

Cenário 4 - Detecção de fraude ou transações financeiras suspeitas - (Artur, Lucio, Ruan)

Problema: Instituições financeiras precisam identificar transações suspeitas em bases geralmente desbalanceadas, nas quais fraudes são raras.

Pergunta central: Como usar agrupamento para identificar padrões normais e anômalos e apoiar um modelo de detecção de fraude ou risco?

Base(s) de dados sugerida(s):

- **Credit Card Fraud Detection - Kaggle:** Base com 284.807 transações, das quais 492 são fraudes, caracterizada por forte desbalanceamento. Link: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>
- **Default of Credit Card Clients - UCI Machine Learning Repository:** Base sobre inadimplência de clientes de cartão de crédito em Taiwan, com foco em previsão de default. Link: <https://archive.ics.uci.edu/ml/datasets/default%2Bof%2Bcredit%2Bcard%2Bclients>

Pipeline possível: Transações ou dados de crédito -> agrupamento de comportamentos financeiros -> identificação de outliers -> predição de fraude ou inadimplência -> alerta de risco.

Técnicas possíveis: DBSCAN, K-Means, autoencoder, árvore de decisão, algoritmo genético para limiares e Random Forest ou rede neural para predição final.

Exemplo de saída esperada: O sistema poderá indicar se uma transação ou cliente apresenta risco, explicando o grupo de comportamento associado e os atributos relevantes.

Cenário 5 - Recomendação educacional e predição de desempenho acadêmico - (Pedro, Felipe e Arthur Inocêncio) OK

Problema: Instituições de ensino desejam identificar perfis de estudantes, prever risco acadêmico e recomendar ações pedagógicas personalizadas.

Pergunta central: Como agrupar estudantes por perfil acadêmico/comportamental e usar esses grupos para prever desempenho ou recomendar intervenções?

Base(s) de dados sugerida(s):

- **Student Performance - UCI Machine Learning Repository:** Base sobre desempenho de estudantes de duas escolas portuguesas, com atributos demográficos, sociais, escolares e notas em Matemática e Português. Link: <https://archive.ics.uci.edu/dataset/320/student%2Bperformance>

Pipeline possível: Dados de estudantes -> agrupamento por perfil acadêmico -> predição de desempenho -> recomendação de intervenção pedagógica.

Técnicas possíveis: K-Means, agrupamento hierárquico, árvore de decisão, rede neural, algoritmo genético para seleção de variáveis e recomendação baseada no perfil.

Exemplo de saída esperada: O sistema poderá identificar perfis como alto desempenho, baixo engajamento ou risco acadêmico e recomendar monitoria, revisão de conteúdo ou acompanhamento individual.

Cenário 6 - Sistema de recomendação de filmes ou conteúdos digitais (Matheus e Alexandre)

Problema: Serviços de streaming e plataformas digitais precisam recomendar conteúdos com base no comportamento de usuários semelhantes.

Pergunta central: Como agrupar usuários por preferências e usar esses grupos para recomendar filmes ou conteúdos?

Base(s) de dados sugerida(s):

- **MovieLens Latest Small - GroupLens:** Base pequena com aproximadamente 100.000 avaliações, 3.600 aplicações de tags, 9.000 filmes e 600 usuários. Link: <https://grouplens.org/datasets/movielens/latest/>
- **MovieLens - GroupLens:** Coleção de bases amplamente utilizadas em sistemas de recomendação. Link: <https://grouplens.org/datasets/movielens/>

Pipeline possível: Avaliações de usuários -> matriz usuário-filme -> agrupamento de usuários semelhantes -> recomendação de filmes por cluster.

Técnicas possíveis: K-Means em vetores de preferências, similaridade cosseno, agrupamento hierárquico, fatoração de matriz, rede neural simples e algoritmo genético para otimizar pesos de gêneros ou similaridades.

Exemplo de saída esperada: O sistema poderá receber um usuário, identificar seu cluster de preferência e recomendar filmes bem avaliados por usuários semelhantes.

7. Entregas semanais

Semana 1 - Base tratada, entendimento do problema e preparação inicial

Entrega obrigatória:

- Identificação do cenário atribuído ao grupo.
- Apresentação da base pública utilizada.
- Descrição do problema e da pergunta de negócio, predição, recomendação ou decisão.

- Descrição inicial dos atributos.
- Tratamento de valores ausentes.
- Tratamento de duplicidades.
- Identificação preliminar de outliers.
- Transformação inicial de atributos categóricos, quando necessário.
- Primeira análise exploratória.
- Divisão dos papéis dos três alunos – Apresentação de nome e papel.
- Repositório ou arquivo inicial do projeto. (preferencialmente repo no gitHub)

Produto esperado: Notebook inicial contendo carregamento da base, análise exploratória e primeira versão da base tratada.

Semana 2 - Agrupamento de Dados I: representação, distância e baseline

Entrega obrigatória:

- Seleção dos atributos para agrupamento.
- Justificativa dos atributos escolhidos.
- Normalização ou padronização.
- Definição da medida de distância ou similaridade.
- Aplicação do primeiro algoritmo de agrupamento.
- Aplicação de pelo menos uma visualização dos dados.
- Análise inicial dos clusters.
- Identificação de problemas no agrupamento inicial.

Produto esperado: Primeiro modelo de agrupamento funcionando, ainda que seja um baseline.

Semana 3 - Agrupamento de Dados II: comparação, validação e interpretação

Entrega obrigatória:

- Aplicação de um segundo algoritmo de agrupamento.
- Comparação entre os algoritmos.
- Uso de pelo menos duas métricas de avaliação.
- Análise dos parâmetros utilizados.
- Interpretação dos clusters.
- Nomeação dos perfis encontrados.
- Definição de como os clusters serão usados na Inteligência Computacional.
- Geração da variável ou estrutura de saída do agrupamento.

Produto esperado: Etapa de Agrupamento de Dados consolidada, com clusters interpretados e prontos para alimentar a etapa de Inteligência Computacional.

Semana 4 - Inteligência Computacional I: construção do modelo inteligente

Entrega obrigatória:

- Definição da tarefa de Inteligência Computacional.
- Escolha justificada da técnica.
- Preparação dos dados para o modelo.
- Construção do modelo inicial.
- Treinamento ou execução da técnica.
- Avaliação preliminar.
- Comparação inicial com e sem uso dos clusters, quando aplicável.

Produto esperado: Modelo inteligente funcional, ainda em versão inicial.

Semana 5 - Inteligência Computacional II e integração final

Entrega obrigatória:

- Refinamento do modelo de Inteligência Computacional.
- Comparação final entre abordagens.
- Análise da contribuição do agrupamento para o modelo inteligente.
- Apresentação da decisão, recomendação ou predição final.
- Demonstração prática da solução.
- Relatório técnico.
- Slides.
- Código final organizado.
- Análise crítica do projeto.

Produto esperado: Solução integrada final, mostrando como Agrupamento de Dados e Inteligência Computacional foram usados em conjunto para resolver o problema.

8. Estrutura mínima do relatório final

- Título do projeto.
- Integrantes e papéis exercidos.
- Cenário atribuído.
- Descrição do problema.
- Justificativa comercial, educacional ou institucional.
- Descrição da base de dados.
- Análise exploratória.
- Pré-processamento.
- Algoritmos de agrupamento utilizados.
- Avaliação dos clusters.
- Interpretação dos grupos.
- Técnica de Inteligência Computacional utilizada.
- Tarefa final: predição, recomendação, classificação, otimização ou decisão.
- Comparação dos resultados com e sem clusters, quando aplicável.
- Limitações da solução.
- Possibilidades de melhoria.
- Conclusão.
- Referências e links das bases utilizadas.
- Link para o repositório ou arquivos do projeto.

9. Critérios de pontuação - distribuição equilibrada

A avaliação sugerida totaliza 100 pontos. A distribuição foi organizada para equilibrar as duas disciplinas e reservar parte da nota para dados, organização e documentação, que são comuns ao projeto.

Bloco	Critério	Pontos
Dados e projeto	Definição do problema, base pública, análise exploratória e preparação inicial	10
Dados e projeto	Organização do código, reprodutibilidade e documentação	10
Agrupamento de Dados	Escolha de atributos, distância/similaridade e pré-processamento para clustering	10

Agrupamento de Dados	Aplicação de pelo menos dois algoritmos de agrupamento	10
Agrupamento de Dados	Avaliação, comparação e interpretação dos clusters	20
Inteligência Computacional	Escolha e justificativa da técnica de IC	10
Inteligência Computacional	Implementação do modelo preditivo, recomendador, otimizador ou decisório	15
Inteligência Computacional	Avaliação do modelo e comparação com/sem clusters	15
Total		100

Resumo da distribuição: 40 pontos para Agrupamento de Dados, 40 pontos para Inteligência Computacional e 20 pontos para dados, projeto, organização e documentação.

10. Avaliação individual dentro do grupo

A nota principal será atribuída ao grupo, mas poderá haver ajuste individual conforme participação efetiva, domínio do código e defesa oral.

Critério individual	Possível ajuste
Participação técnica comprovada por commits, notebooks ou entregas	até +10%
Clareza na apresentação oral	até +5%
Domínio do código desenvolvido	até +5%
Ausência de contribuição comprovada	redução proporcional
Não domínio da própria parte	redução proporcional

Cada aluno deverá apresentar sua parte e responder perguntas sobre ela. Os professores poderão questionar qualquer integrante sobre o funcionamento geral da solução.

11. Regras acadêmicas e observações finais

- O uso de bibliotecas é permitido, mas o grupo deve explicar o que foi feito e justificar as escolhas técnicas.
- Não será aceito trabalho composto apenas por execução automática de bibliotecas sem análise crítica.
- **Rótulos reais** existentes na base **não devem ser usados para formar os clusters**; eles podem ser usados apenas para avaliação posterior, quando adequado.
- O uso de ferramentas de IA generativa é permitido apenas como apoio, desde que o grupo compreenda, adapte e explique o código produzido.
- Plágio de notebooks, artigos, repositórios ou respostas prontas implicará perda de nota.
- A demonstração prática deverá mostrar a solução funcionando.

12. Checklist final para os alunos

- O cenário atribuído foi mantido?
- A base pública foi corretamente carregada e documentada?
- A base foi tratada e preparada?
- Foram aplicados pelo menos dois algoritmos de agrupamento?
- Os clusters foram avaliados com métricas adequadas?
- Os perfis foram interpretados?
- Foi aplicada pelo menos uma técnica de Inteligência Computacional?
- A técnica de IC foi avaliada com métricas adequadas?

- Foi feita integração real entre clusterização e IC?
- A solução gera predição, recomendação, priorização, classificação, otimização ou decisão?
- O código está organizado e reproduzível?
- O relatório explica as decisões e limitações?
- A apresentação contém demonstração prática?

13. Referências e links úteis das bases sugeridas

- Online Retail - UCI: <https://archive.ics.uci.edu/dataset/352/online%2Bretail>
- Telco Customer Churn - Kaggle: <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>
- Telco Customer Churn - IBM:
<https://www.ibm.com/docs/en/cognos-analytics/12.0.x?topic=samples-telco-customer-churn>
- Bank Marketing - UCI: <https://archive.ics.uci.edu/dataset/222/bank%2Bmarketing>
- Credit Card Fraud Detection - Kaggle: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>
- Default of Credit Card Clients - UCI:
<https://archive.ics.uci.edu/ml/datasets/default%2Bof%2Bcredit%2Bcard%2Bclients>
- Student Performance - UCI: <https://archive.ics.uci.edu/dataset/320/student%2Bperformance>
- MovieLens Latest Small - GroupLens: <https://grouplens.org/datasets/movielens/latest/>
- MovieLens - GroupLens: <https://grouplens.org/datasets/movielens/>